

PRML 作业二报告

王子棋

850973583@qq.com

摘要

这是一篇关于使用 **Decision Trees**, **AdaBoost + DecisionTrees**, 与 **SVM** 算法来对三维数据进行分类, 观察其训练结果与测试相似度, 并尝试解释为什么有的算法效果更好或某些算法的某些方式效果更好并解释分析其原因的报告。

介绍

Decision Trees, **AdaBoost + DecisionTrees**, 与 **SVM** 算法是对多个三维离散数据进行区分的常见通用方法, 但拟合效果各不相同, SVM 算法中选用不同的核函数也不同。因此要进行分析某些算法分离效果更好的原因。

方法

如下是此次研究使用到的方法

方法一: Decision Trees

决策树是一种模拟人类决策过程的监督学习算法。它将数据集根据特征不断进行二分 (Binary Split), 最终形成一棵倒立的树结构: 根在最上方, 叶子在最下方。

方法二: AdaBoost + DecisionTrees

AdaBoost 的核心逻辑是通过迭代训练一系列弱分类器 (准确率仅略高于 50% 的模型), 并将它们组合成一个强分类器。

弱分类器 (Weak Learner): 在这个组合中, 通常是深度为 1 的决策树 (即只有一个分裂点, 只按一个特征划分一次)。

自适应 (Adaptive): AdaBoost 会根据前一轮的表现, 动态调整样本的“权重”

方法三: SVM 算法

它的核心目标不仅是找到一个能把数据分开的边界, 而是要找到一个“最优”边界——这个边界要尽可能地远离所有类别的样本点。

实验现象分析




图 1.1 5 种方法的 2 维效果图

方法	准确率
Decision Trees	0.822
AdaBoost + DecisionTrees	0.970
SVM(linear)	0.700
SVM (poly d=3)	0.876
SVM(RBF)	0.980

表 1.1 5 种方法的准确率

由 5 张图可以直观看出方法之间的区别。

SVM (Linear Kernel - 线性核) 表现最差

三维双月数据集是高度非线性可分的。两个类别的数据在空间中相互交错缠绕，根本无法用一个平坦的二维超平面 (Hyperplane) 将它们完全切开。线性 SVM 只能寻找线性边界，因此在这个问题上存在严重的欠拟合。

Decision Trees (决策树) 表现一般

决策树通过在特征轴上进行正交划分 (切分平行于坐标轴) 来进行分类。虽然它可以逼近非线性边界，但在处理像“新月”这样平滑且斜向交错的几何形状时，决策树会生成非常复杂的、阶梯状的决策边界。这使得它容易对训练集中的高斯噪音过拟合，导致在测试集上的泛化能力不如强力的非线性模型。

AdaBoost + Decision Trees 很优秀，准确率很高

虽然它底层使用的是非常简单的“弱分类器” (比如深度为 1 的决策树桩)，但它通过多轮迭代，让后续的树专注于前面分类错误的困难样本 (即两个月亮交界处、或者被噪音干扰的点)。多个弱分类器的线性组合能够极其平滑和精准地拟合出复杂的非线性边界，有效克服了单一决策树易过拟合的缺点。

SVM (Poly Kernel - 多项式核) 表现稍好

Poly 核通过多项式变换将数据映射到更高维的空间，使得原本非线性的数据变得更容易用超平面分开。

SVM (RBF Kernel - 高斯核) 正确率最高

RBF 核本质上将数据映射到了无限维的特征空间。RBF 核的工作原理类似于度量样本之间的相似度，对于这种局部聚集、形状复杂的簇 (如双月形状)，RBF 核能够非常完美地顺应数据的几何分布，刻画出极其平滑且贴合的非线性决策边界，因此在这个问题上表现得游刃有余。

实验结论

模型选择应与数据几何特征相匹配。对于像 Make-Moons 这样具有明显空间流形特征 (弯曲、缠绕) 的数据集，非线性核函数 (RBF) 是首选方案。集成学习 (AdaBoost) 虽然强大，但需要足够的迭代深度或更复杂的基分类器才能突破线性瓶颈。而线性模型在处理此类非线性结构时，即便在更高维度 (3D) 也存在严重的性能上限。