

PRML 作业三报告

王子棋

850973583@qq.com

摘要

本实验以北京逐小时空气质量数据为基础，采用 LSTM 长短期记忆网络构建多变量时间序列预测模型。通过对气象、污染等多特征进行数据预处理、标准化与时序样本构造，利用前 24 小时监测数据预测下一小时 PM2.5 浓度。实验结果表明，LSTM 模型能有效捕捉时序依赖关系，预测结果与真实值趋势基本一致，可实现较为准确的空气质量短期预测，为环境监测与预警提供有效方法。

介绍

传统 RNN 在处理长序列数据时，因反向传播过程中梯度连乘导致梯度消失或梯度爆炸，无法有效捕捉长距离依赖关系。而 LSTM 通过独特的门控机制与细胞状态设计，成功缓解了这一问题，成为序列建模的基础算法。

LSTM 的核心结构由细胞状态（Cell State）和三个门控单元组成。细胞状态作为信息传递的“载体”，呈线性流动，最大限度减少信息损耗；三个门控单元（遗忘门、输入门、输出门）均通过 sigmoid 激活函数实现 0-1 区间的输出，精准控制信息的筛选与传递。

具体工作逻辑为：遗忘门筛选并丢弃历史细胞状态中的冗余信息；输入门筛选当前输入的有效特征，生成候选记忆并更新至细胞状态；输出门控制细胞状态的输出范围，最终生成当前隐藏状态，完成长序列信息的有效记忆与处理。

LSTM 的应用场景广泛，主要集中在序列相关任务，包括自然语言处理（文本分类、机器翻译、命名实体识别）、时间序列预测（股价、流量预测）以及语音识别、视频帧序列分析等领域。

方法

本研究采用多变量时间序列预测方法，基于 LSTM（长短期记忆网络）构建 PM2.5 浓度预测模型。整体流程包括数据预处理、时序数据构造、LSTM 模型构建、模型训练与评估四个部分。


数据预处理对原始数据进行时间格式转换、缺失值检查，对风向等分类特征进行独热编码，使模型能够处理文本类型变量。为提升模型训练稳定性，使用 MinMaxScaler 将所有特征与目标变量归一化至 [0,1] 区间。

时序样本构建以过去 24 小时的气象与污染数据作为输入特征，预测未来 1 小时的 PM2.5 浓度，构建符合 LSTM 输入格式的三维时序数据（样本数 × 时间步 × 特征数）。

LSTM 模型构建采用双层 LSTM 结构，第一层用于提取短期时序依赖，第二层提取高阶时序特征；中间加入 Dropout 层防止过拟合；最终通过全连接层输出预测值。模型使用 Adam 优化器与均方误差（MSE）损失函数进行训练。

模型训练与评估按时间顺序划分训练集与测试集，避免数据泄露。使用平均绝对误差（MAE）和均方根误差（RMSE）评估预测效果，并通过可视化对比真实值与预测值的趋势一致性。

实验现象分析



结果如图所示。训练过程现象模型在训练初期损失下降较快，说明 LSTM 能快速学习时序特征；随着迭代次数增加，训练损失与验证损失逐渐趋于平稳，未出现明显的发散或剧烈波动，表明模型结构稳定，未产生严重过拟合或欠拟合。

预测趋势现象预测曲线与真实值曲线整体变化趋势基本一致，能够较好地捕捉 PM2.5 浓度的上升、下降与波动规律，说明模型有效学习了气象因素与污染浓度之间的时序依赖关系。

误差分布现象在浓度平稳时段，预测值与真实值接近，误差较小；在污染浓度突然升高或骤降的突变点，预测存在一定滞后，误差相对偏大，这是时序预测的常见现象。

多变量贡献现象温度、露点、气压、风向等多变量共同输入，使模型获得更全面的环境信息，预测效果明显优于单一变量预测，体现了多变量 LSTM 在时序预测中的优势。

整体效果现象 MAE 与 RMSE 均处于合理范围，预测精度满足短期空气质量预测需求，表明基于 LSTM 的多变量时序预测方法有效、可行。

实验结论

本实验基于 LSTM 神经网络完成多变量 PM2.5 浓度时序预测任务。通过对数据集进行时间转换、独热编码、标准化及时序样本构建，搭建了双层 LSTM 预测模型。实验结果表明，该模型能够有效学习历史气象与污染数据的时序依赖关系，较为准确地预测未来一小时的 PM2.5 浓度。模型整体趋势拟合良好，误差指标合理，证明 LSTM 在多变量时间序列预测中具有明显优势，可用于空气质量短期预警与预测，具备一定的实际应用价值。