

PRML 作业 4 报告

王子棋

850973583@qq.com

摘要

本文针对 2017 年经典论文《Attention Is All You Need》进行复现，聚焦 Transformer 核心模块位置编码开展消融对比实验。Transformer 摒弃了传统循环神经网络、卷积神经网络结构，完全依靠自注意力机制完成序列建模，但模型本身不具备时序感知能力，必须依靠位置编码注入序列顺序信息。本次实验搭建原版正弦位置编码、可学习位置编码、简单绝对位置编码三种对照模型，基于英德翻译数据集进行训练，通过损失值收敛情况、BLEU 翻译指标分析不同位置编码的性能差异。实验结果表明：原文正弦位置编码收敛速度最快、翻译精度最高；可学习位置编码性能次之；简单绝对位置编码效果最差。验证了位置编码是 Transformer 序列建模的必要模块，且正弦位置编码具备无参、泛化性强、可建模相对位置的独特优势。

介绍

在 Transformer 问世之前，主流序列翻译模型依托循环神经网络(RNN)、卷积神经网络(CNN)搭建编码解码结构。RNN 存在串行计算、长距离梯度消失问题；CNN 依赖堆叠卷积层扩大感受野，长序列建模能力薄弱。2017 年 Vaswani 等人提出 Transformer 架构，彻底舍弃循环与卷积结构，仅依靠自注意力机制实现全局序列依赖捕捉，具备极强并行计算能力，大幅提升机器翻译效果。

自注意力机制运算过程中，词向量之间无顺序区分，模型无法天然识别文本语序，严重影响序列任务效果。因此位置编码成为 Transformer 不可或缺模块，但不同位置编码对模型性能的影响尚不明确。本文针对该问题开展消融实验，探究：①位置编码在 Transformer 中的核心作用；②原版正弦位置编码相较于其他编码方式的优越性。

方法

本研究采用 transformer 基础架构，整体采用编码-解码架构。


核心模块有

1. 通过查询矩阵 Q 、键矩阵 K 、值矩阵 V 计算注意力权重，引入缩放系数规避维度过高导致的梯度饱和问题，同时添加掩码屏蔽无效 padding 字符与未来时序信息。
2. 将单个注意力头拆分为 8 个并行子空间，分别捕捉不同维度的语义依赖，最后拼接多头特征，增强模型特征提取能力。
3. 每一层网络添加残差连接，缓解深度模型梯度消失问题；搭配层归一化统一数据分布，加速模型收敛。

并通过 3 种位置编码设计

1. 正弦位置编码。论文原生编码方式，无训练参数，利用三角函数周期性生成位置向量，偶数维度使用正弦函数、奇数维度使用余弦函数，可天然建模相对位置关系，适配任意长度序列。
2. 可学习位置编码。构建可训练的嵌入层，随机初始化位置向量，模型在训练过程中自适应学习位置信息，具备一定拟合能力，但存在额外参数量。
3. 简单绝对位置编码。采用独热编码结合线性映射生成位置向量，仅记录绝对位置坐标，无法刻画字符之间的相对语序关系，结构最简单。

实验现象分析



结果如图所示。正弦位置编码 loss 下降最快，可学习位置编码下降次之，简单绝对位置编码效果最差。

正弦编码优势原因：三角函数具备周期性，可计算字符间相对位置，贴合自然语言语序逻辑；无需训练参数，不会产生过拟合，泛化能力强；

可学习编码劣势原因：依赖数据学习位置信息，小数据集下拟合不足，且参数量大，训练成本高；

简单绝对编码劣势原因：仅记录孤立绝对位置，无法表征字符先后逻辑，语序建模能力缺失，翻译准确率最低。

实验结论

1. 位置编码核心作用

Transformer 自注意力机制无内置时序感知能力，词向量无序、无先后区分。位置编码是 Transformer 建模序列语序的必要模块，核心作用为：向词向量注入绝对位置信息与相对位置依赖，让模型识别文本语序、区分不同位置的相同字符，是序列任务能够正常训练的前提。

2. 不同编码方式总结

原版正弦位置编码：无训练参数、收敛速度快、具备相对位置建模能力、泛化性优异，综合性能最优；

可学习位置编码：自适应能力较强，但依赖大数据集、参数量大、泛化能力一般；

简单绝对位置编码：结构简单，仅能记录绝对位置，无法建模语序依赖，不适用于自然语言序列任务。

3. 本次实验成功复现 Transformer 基础架构，完成位置编码消融对照实验，验证了论文设计的合理性。原始论文选用正弦位置编码，兼顾性能、参数量与泛化能力，适配各类序列任务。

本次实验存在数据集规模小、模型层数少的局限性，后续可采用大规模翻译数据集，进一步验证长序列下不同位置编码的性能差异。同时，本次实验也证明 **Transformer** 每一个模块均有设计逻辑，合理的模块选择是模型性能优异的关键。